


Análisis de Descomposición


Graficamos la serie temporal



La gráfica muestra una tendencia general **ascendente**, lo que indica que el IPC ha aumentado a lo largo del tiempo.

Su tendencia

Esta imagen parece mostrar la tendencia a largo plazo de la serie temporal, suavizando las fluctuaciones.

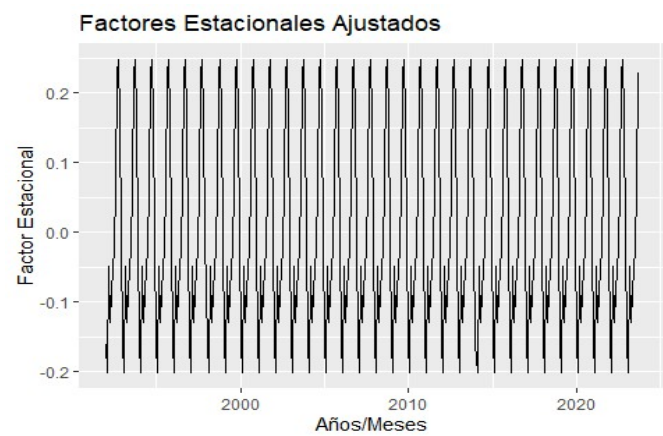


Obtenemos los factores estacionales, los factores estacionales reflejan los patrones recurrentes que se repiten en intervalos regulares dentro de la serie temporal.

```
[1] "Factores Estacionales:"
> print(St)
```

1	2	3	4	5	6
-0.161045363	-0.201457090	-0.047945569	-0.129982945	-0.087786539	-0.050929513
7	8	9	10	11	12
-0.023477985	0.066848562	0.228302877	0.248179135	0.166769033	-0.007474603

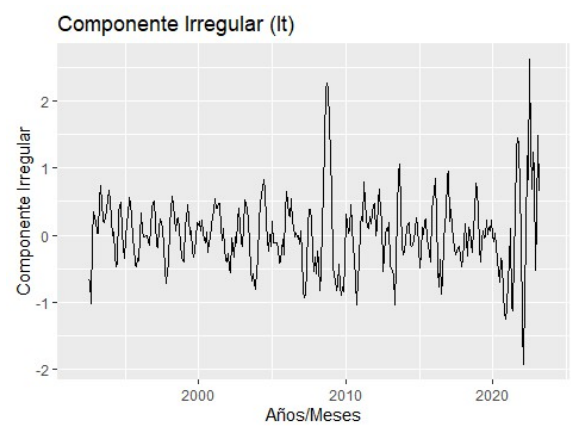
Serie de factores estacionales ajustados para la serie temporal completa



El gráfico confirma la naturaleza cíclica y repetitiva de los factores estacionales en los datos. Los ciclos anuales muestran un patrón consistente a lo largo de los años. Esto indica que las variaciones estacionales son estables y predecibles,

Componente irregular

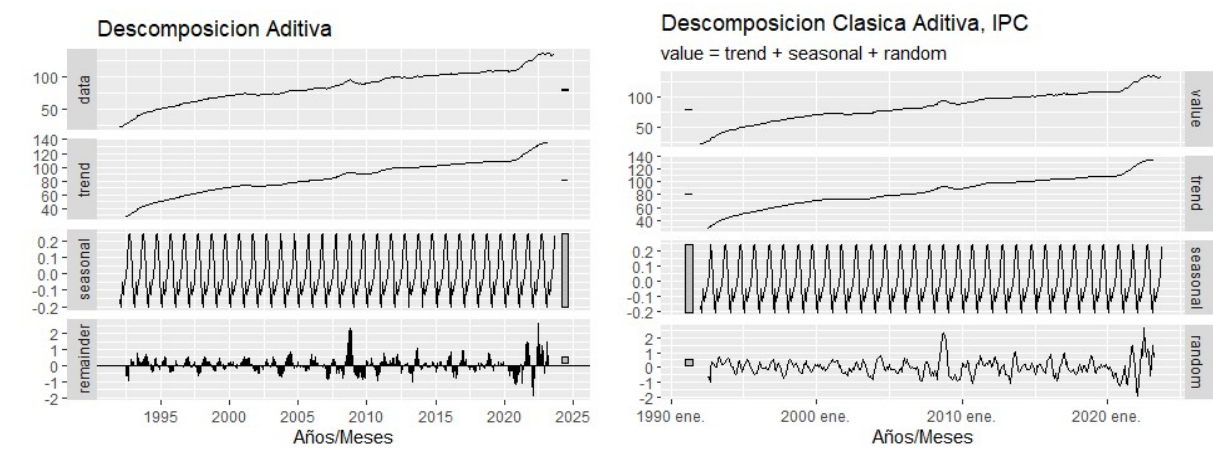
El componente irregular representa las variaciones aleatorias o ruido que no siguen un patrón de tendencia o estacionalidad.



Este componente captura las fluctuaciones aleatorias y de corto plazo en los datos que no se pueden atribuir a tendencias, estacionalidades o patrones cíclicos. Es esencialmente el "ruido" o las variaciones impredecibles en la serie temporal.

Descomposición Aditiva.


La descomposición aditiva es útil cuando las variaciones en la serie temporal son relativamente constantes.



Modelo Multiplicativo

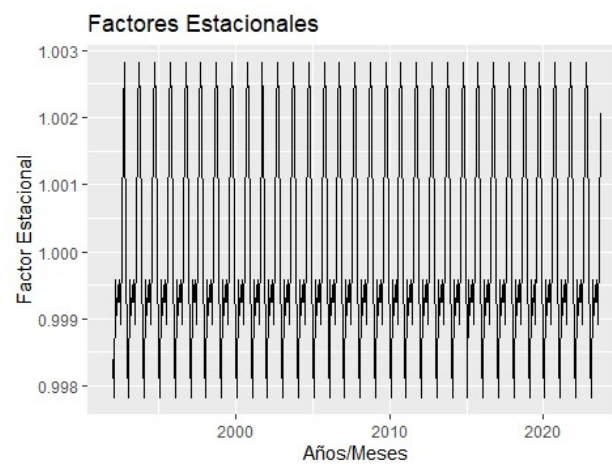
A diferencia de la descomposición aditiva, el modelo multiplicativo se utiliza cuando las variaciones en los datos cambian en proporción al nivel de la serie. Es útil para series con variaciones que no son constantes.

Componente Tendencia ciclo [Tt=TCt]

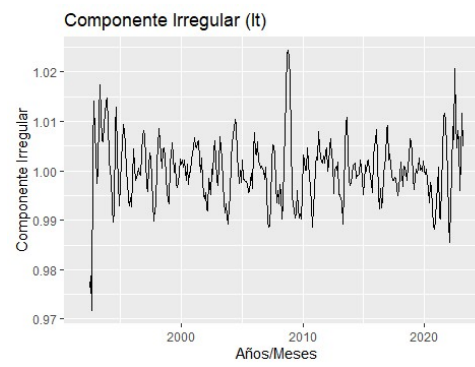


Factores Estacionales

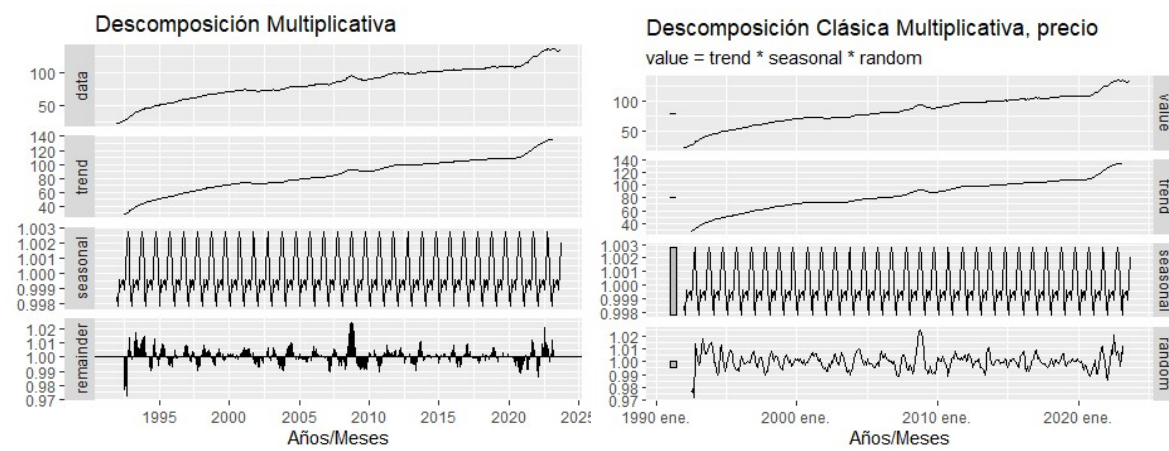
```
[1] "Factores Estacionales:"
> print(St)
      1      2      3      4      5      6      7      8      9
0.9983957 0.9978241 0.9995862 0.9990637 0.9994232 0.9995755 0.9989145 1.0001529 1.0020497
     10     11     12
1.0028185 1.0021352 1.0000607
```



Componente Irregular



Descomposición multiplicativa



Ambas descomposiciones muestran un patrón estacional claro y una tendencia al alza en el IPC.

Modelamiento ARIMA

ARIMA(2,1,1)(1,0,0)[12] with drift

Coefficients:

	ar1	ar2	ma1	sar1	drift
	1.0835	-0.1868	-0.6416	-0.0796	0.2971
s.e.	0.1778	0.1221	0.1625	0.0583	0.0716

sigma^2 = 0.1954: log likelihood = -226.7
AIC=465.4 AICc=465.62 BIC=489.04

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.0008747821	0.4385175	0.3098639	0.02761451	0.3766783	0.08062163

ACF1
Training set 0.003244953

Estos coeficientes representan la influencia de los términos autorregresivos, de media móvil y estacional en el modelo, junto con el término de drift que indica una tendencia constante a lo largo del tiempo.

ARIMA(2,1,1):

- **p=2:** Este es el orden autorregresivo (AR) del modelo. Indica que el modelo utiliza las dos observaciones anteriores (lags) para predecir el valor actual. Es decir, el modelo incluye dos términos de autorregresión.
- **d=1:** Este es el orden de diferenciación. Indica que la serie ha sido diferenciada una vez para hacerla estacionaria. La diferenciación es un método para eliminar la tendencia de la serie.
- **q=1:** Este es el orden de la media móvil (MA). Indica que el modelo utiliza un término de media móvil basado en el error de predicción de la observación anterior.


(1,0,0)[12]:

- **P=1:** Este es el orden autorregresivo estacional. Indica que el modelo incluye un término AR estacional basado en las observaciones de un periodo anterior (por ejemplo, un año si la frecuencia es mensual).
- **D=0:** Este es el orden de diferenciación estacional. En este caso, no se ha realizado ninguna diferenciación estacional.
- **Q=0:** Este es el orden de la media móvil estacional. Aquí no se incluye ningún término de media móvil estacional.
- **[12]:** Este es el periodo de la estacionalidad, que en este caso es 12, lo que indica una estacionalidad anual.

Drift:

- **Drift:** Este término representa una tendencia lineal en la serie temporal después de la diferenciación. El "drift" es como un intercepto que se reintroduce en el modelo diferenciado, permitiendo capturar una tendencia lineal residual en los datos.

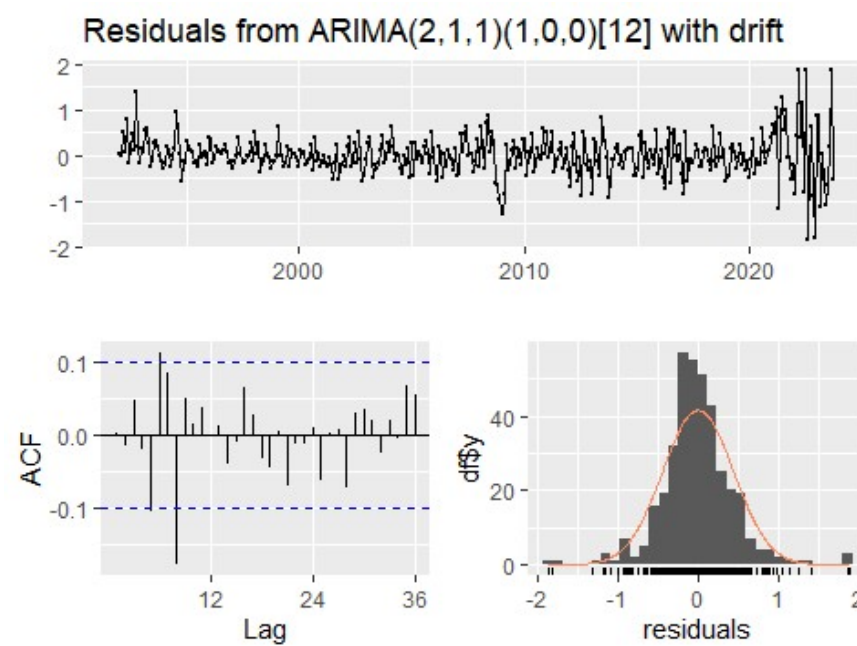
Correlogramas simple y parcial



En autocorrelación parcial el primer retardo tiene una correlación significativa, lo que sugiere que el primer término autoregresivo (AR) es importante en la serie.

En la autocorrelación simple el gráfico muestra una disminución gradual en la autocorrelación a medida que aumenta el lag.

Diagnóstico del modelo




El gráfico de los residuos estos, parecen estar centrados alrededor de cero, aunque hay un aumento en la variabilidad hacia el final del período.

La mayoría de los puntos están dentro de las líneas punteadas azules, lo que sugiere que no hay autocorrelación significativa en los residuos.

Los residuos parecen estar distribuidos aproximadamente de manera normal.

Predicciones de 12 periodos



Test de Raíz Unitaria

Prueba de Dickey-Fuller Aumentada (ADF)

Augmented Dickey-Fuller Test

```
data: serie.ts
Dickey-Fuller = -3.6673, Lag order = 7, p-value = 0.02669
alternative hypothesis: stationary
```

Con un valor p de 0.02669, podemos rechazar la hipótesis nula de que la serie tiene una raíz unitaria (no es estacionaria) al nivel de significancia del 5%. Esto significa que hay suficiente evidencia para concluir que la serie temporal es **estacionaria**.

Prueba de Phillips-Perron (PP)

Augmented Dickey-Fuller Test

```
data: serie.ts
Dickey-Fuller = -4.2171, Lag order = 0, p-value = 0.01
alternative hypothesis: stationary
```


Con un valor p de 0.01, podemos rechazar la hipótesis nula de que la serie tiene una raíz unitaria (no es estacionaria) al nivel de significancia del 5%. Esto significa que hay suficiente evidencia para concluir que la serie temporal es **estacionaria**.

Prueba de Kwiatkowski-Phillips-Schmidt-Shin (KPSS)

```
#####
# KPSS Unit Root Test #
#####

Test is of type: mu with 5 lags.

Value of test-statistic is: 6.0145

Critical value for a significance level of:
      10pct  5pct  2.5pct  1pct
critical values 0.347 0.463  0.574 0.739
```

El valor del test estadístico (6.0145) es **significativamente mayor** que los valores críticos para todos los niveles de significancia (10%, 5%, 2.5%, 1%). Dado que el valor del test estadístico excede los valores críticos, **se rechaza la hipótesis nula** de estacionariedad.

Test de Zivot-Andrews

```
#####
# Zivot-Andrews Unit Root Test #
#####

Call:
lm(formula = testmat)

Residuals:
    Min       1Q   Median       3Q      Max
-1.73026 -0.25940 -0.03251  0.21704  1.97771

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.836948   0.217366   8.451 6.47e-16 ***
y.l1         0.968887   0.004816 201.179 < 2e-16 ***
trend        0.005346   0.001035   5.164 3.94e-07 ***
du           1.757308   0.187160   9.389 < 2e-16 ***
dt          -0.059470   0.011064  -5.375 1.35e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

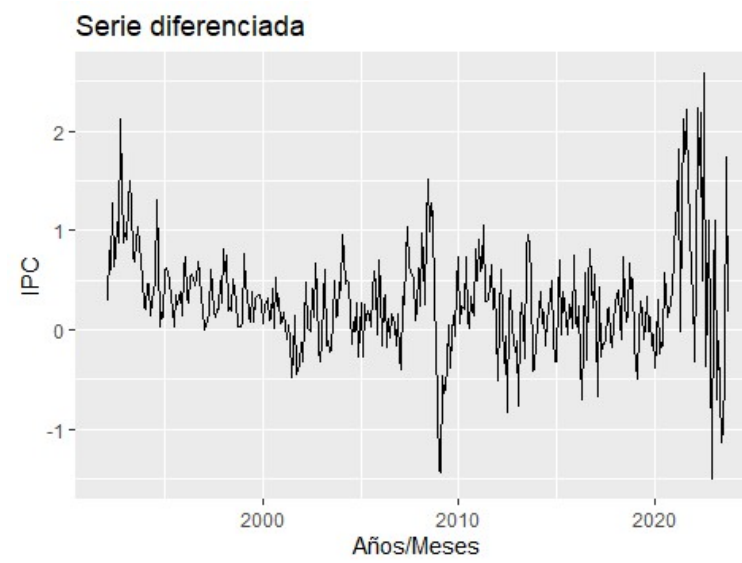
Residual standard error: 0.4639 on 375 degrees of freedom
(1 observation deleted due to missingness)
Multiple R-squared:  0.9996,    Adjusted R-squared:  0.9996
F-statistic: 2.656e+05 on 4 and 375 DF,  p-value: < 2.2e-16

Teststatistic: -6.4604
Critical values: 0.01= -5.57 0.05= -5.08 0.1= -4.82


Potential break point at position: 353
```


Dado que el estadístico de prueba es menor que los valores críticos, podemos rechazar la hipótesis nula de que la serie tiene una raíz unitaria con un quiebre estructural. Esto indica que la serie es **estacionaria con un cambio estructural**.

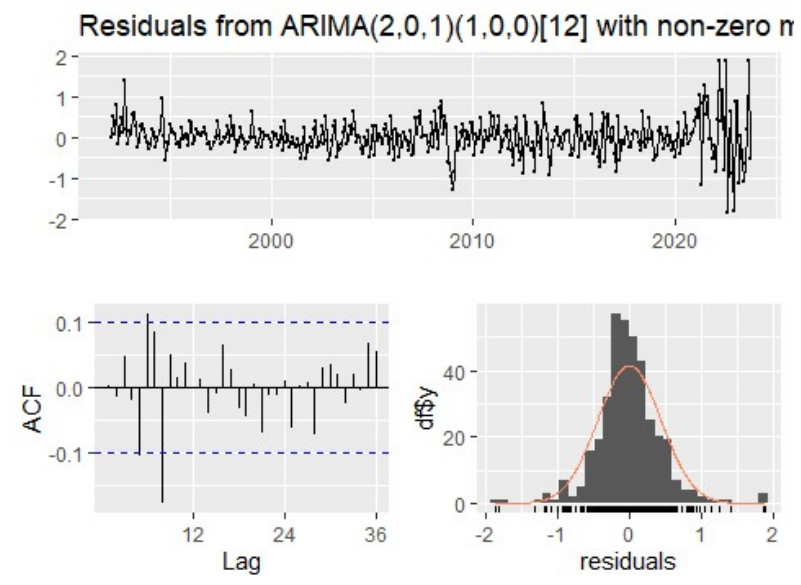
Diferenciando la serie tenemos



Con los siguientes correlogramas



Diagnóstico del modelo



Predicciones

